

Aluno: 2728206 César Grossi

Professor: André Eugenio Lazzaretti

Disciplina: Deep Learning

Relatório: Assignment 05 - Deep Feedforward Neural Networks

Introdução

Este trabalho tem como objetivo aplicar Redes Neurais do tipo Multilayer Perceptron (MLP) para resolver o problema proposto no desafio Spaceship Titanic, cujo objetivo é prever quais passageiros foram transportados para outra dimensão. Foram avaliadas diferentes configurações de rede, técnicas de regularização e otimizadores, analisando seus impactos no desempenho e na capacidade de generalização do modelo.

• Base de Dados e Pré-processamento

O conjunto de dados contém variáveis numéricas e categóricas, além de valores ausentes. Os atributos numéricos foram tratados por meio de imputação pela mediana e normalização com StandardScaler. As variáveis categóricas foram preenchidas com o valor mais frequente e codificadas utilizando One-Hot Encoding. O conjunto foi dividido em dados de treino e validação de forma estratificada, preservando a proporção das classes.

• Modelo Base

O modelo base consiste em uma rede neural com uma única camada oculta contendo 64 neurônios, função de ativação ReLU e otimizador ADAM. Foram utilizados regularização L2 e early stopping. A curva de aprendizado mostra que a acurácia de treino cresce rapidamente, enquanto a de validação permanece inferior, caracterizando uma leve tendência ao sobreajuste. A acurácia obtida no conjunto de validação foi aproximadamente 0,7746.

• Modelo Melhorado 1 – ADAM

No primeiro modelo aprimorado, foi aplicado Grid Search para ajuste dos hiperparâmetros, incluindo número de neurônios, taxa de aprendizado, tamanho do batch e coeficiente de regularização L2. O uso do otimizador ADAM proporcionou convergência estável e melhor desempenho geral. A acurácia de validação alcançada foi de aproximadamente 0,7878, com valor médio de validação cruzada

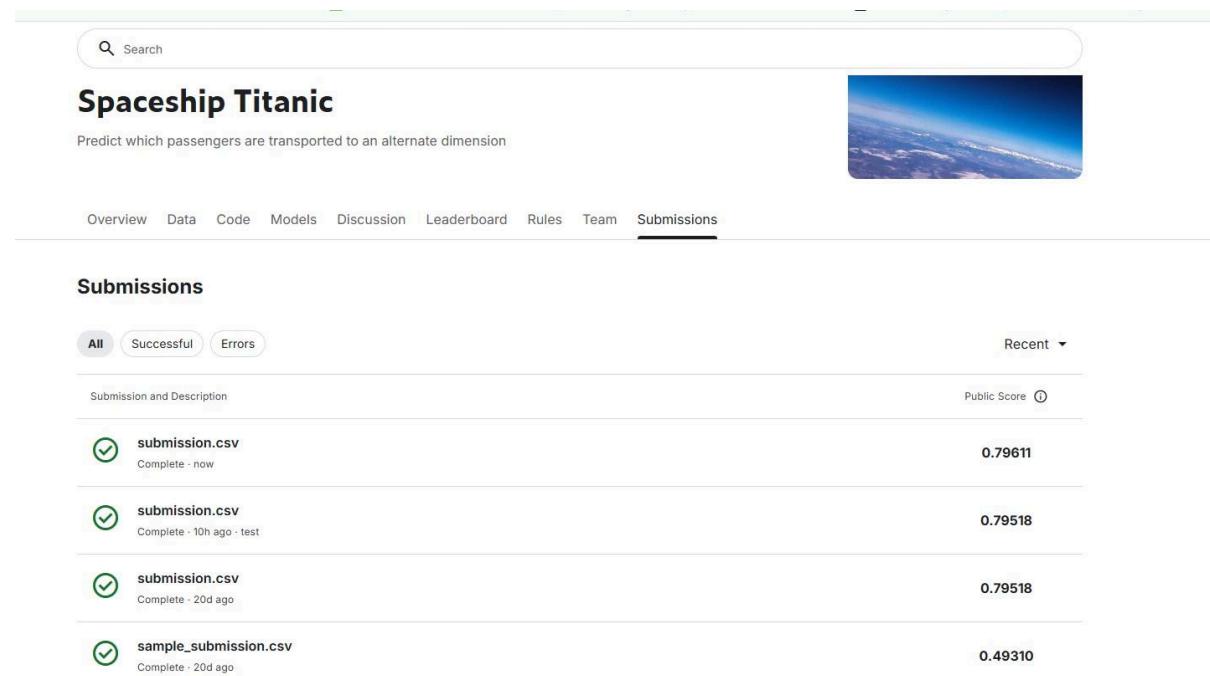
em torno de 0,7908. Observou-se redução do sobreajuste e melhora na capacidade de generalização.

- **Modelo Melhorado 2 – SGD**

O segundo modelo aprimorado utilizou o otimizador SGD, permitindo avaliar o impacto da troca do método de otimização. Foram testadas diferentes taxas de aprendizado, valores de momentum e níveis de regularização. Embora o SGD exija maior ajuste fino, apresentou bom equilíbrio entre viés e variância. A acurácia de validação alcançada foi de aproximadamente 0,7941, sendo a melhor entre os modelos testados.

- **Avaliação no Kaggle**

O modelo selecionado foi utilizado para gerar previsões sobre o conjunto de teste oficial do Kaggle. As submissões realizadas apresentaram pontuações públicas de 0,79518 e 0,79611. O melhor resultado obtido (0,79611) é coerente com a acurácia observada na validação local, indicando boa capacidade de generalização e ausência de sobreajuste significativo.



The screenshot shows the Kaggle competition interface for the Spaceship Titanic challenge. At the top, there's a search bar and the competition title "Spaceship Titanic". Below the title, a subtitle reads "Predict which passengers are transported to an alternate dimension". To the right of the title is a small thumbnail image of a space scene. Below the title, there are navigation links: Overview, Data, Code, Models, Discussion, Leaderboard, Rules, Team, and Submissions. The "Submissions" link is underlined, indicating the current page. The main area is titled "Submissions" and contains a table of submitted files. The table has columns for file name, status, submission time, and public score. There are four rows:

File	Status	Submitted	Public Score
submission.csv	Successful	Complete - now	0.79611
submission.csv	Successful	Complete - 10h ago - test	0.79518
submission.csv	Successful	Complete - 20d ago	0.79518
sample_submission.csv	Successful	Complete - 20d ago	0.49310

- **Comparação Geral dos Modelos**

A comparação entre os modelos mostra que o modelo base apresenta desempenho inferior. O modelo otimizado com ADAM melhora a estabilidade e a acurácia, enquanto o modelo com SGD alcança o melhor resultado final. A escolha adequada de hiperparâmetros, aliada à regularização e ao uso de early stopping, foi fundamental para obter melhores resultados.

- Conclusão

Os experimentos demonstram que o desempenho de redes neurais depende fortemente da escolha da arquitetura, do otimizador e dos hiperparâmetros. A aplicação de Grid Search, aliada à regularização e validação cruzada, permitiu melhorar significativamente a capacidade de generalização do modelo. O modelo baseado em SGD apresentou o melhor desempenho final, sendo considerado o mais adequado para este problema.